

Test af andel i populationer

Test af andel i en population

(se bogen: 8.1.2)

Example 8.3 About 13% of the population is left-handed. A biologist suspects that the scientific community is not like the general population in terms of handedness. He will conduct a study, and if the P -value from his test is less than 5%, he will conclude that the evidence supports his theory. He queries 200 scientists and finds that 36, or 18%, are left-handed. Does this data support the biologist's theory?

Test af andel i en population

(se bogen: 8.1.2)

Example 8.3 About 13% of the population is left-handed. A biologist suspects that the scientific community is not like the general population in terms of handedness. He will conduct a study, and if the P -value from his test is less than 5%, he will conclude that the evidence supports his theory. He queries 200 scientists and finds that 36, or 18%, are left-handed. Does this data support the biologist's theory?

Model: Antal $X \sim \text{Binom}(n, p)$ hvor n er kendt.

Nulhypotese: $H_0: p = p_0 = 0.13$ i eksemplet

Test: Teststørrelse: X . p -værdi: beregn binomialsandsynlighed, at X er mindst så ekstrem som den observerede værdi x . Brug $p = p_0$.

eksemplet
 $x = 36$
 $n = 200$

$$P(X \leq x) = \sum_{k=0}^x \binom{n}{k} p_0^k (1-p_0)^{n-k}$$

$$H_A: p < p_0 \quad p\text{-værdi} = P(X \leq x)$$

$$H_A: p > p_0 \quad p\text{-værdi} = P(X \geq x) = 1 - P(X \leq x-1)$$

$$(H_A: p \neq p_0) \quad p\text{-værdi} = 2 \cdot \min(P(X \leq x), P(X \geq x)) \leftarrow \text{biologens valg}$$

i \textcircled{R} : $P(X \leq x) = \text{pbinom}(x, n, \text{prob}=p_0)$
her: $\text{pbinom}(36, 200, 0.13)$

$$P(X \geq x) = 1 - \underbrace{P(X \leq x)}_{x \in \text{udf. rum}}$$

$$= 1 - \mathbb{P}(X \leq x-1) \\ = 1 - \text{pbinom}(35, 200, 0.13)$$

$$p1 \leftarrow \text{pbinom}(36, 200, 0.13) \\ p2 \leftarrow 1 - \text{pbinom}(35, 200, 0.13)$$

$$2 * \min(p1, p2)$$

Fun fact:

når teststørrelsen T er kontinuert,
så gælder, at under H_0

$$\text{p-value} : \mathbb{P}(T > t_{\text{obs}}) \\ < t_{\text{obs}}$$

hvis vi gentages mange samples
fra H_0 : \Rightarrow forskellig p-værdi
hver gang

\Rightarrow p-værdi af random sample $\sim U[0,1]$

Bootstrap t-tests

Bootstrap t-test

(se bogen: 8.2)

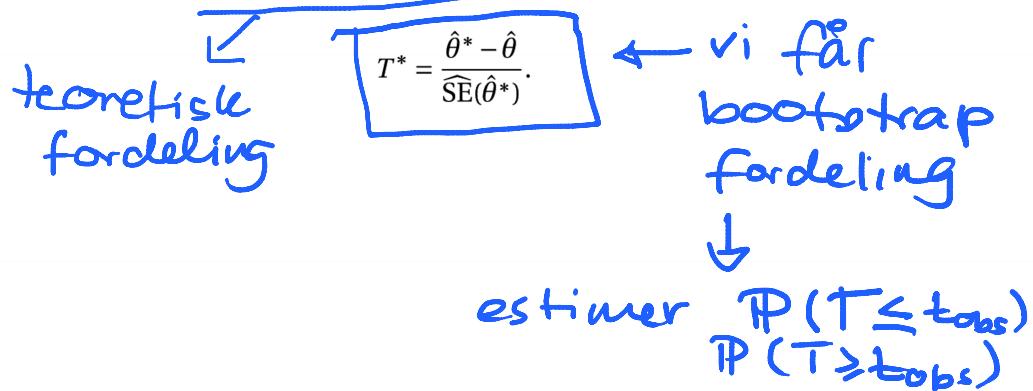
Formål: test $H_0 : \theta = \theta_0$.

Teststørrelse:

$$T = \frac{\hat{\theta} - \theta_0}{\widehat{SE}(\hat{\theta})}.$$

Problem: Stikprøvefordeling af $\hat{\theta}$ er ikke normal $\Rightarrow T$ har ikke en t -fordeling.

Bootstrap-idé: Erstat stikprøvefordeling af T ved bootstrapfordelingen af



Bootstrap t-test

(se bogen: 8.2)

Formål: test $H_0 : \theta = \theta_0$.

Teststørrelse:

$$T = \frac{\hat{\theta} - \theta_0}{\widehat{SE}(\hat{\theta})}.$$

Problem: Stikprøvefordeling af $\hat{\theta}$ er ikke normal $\Rightarrow T$ har ikke en t -fordeling.

Bootstrap-idé: Erstat stikprøvefordeling af T ved bootstrapfordelingen af

$$T^* = \frac{\hat{\theta}^* - \hat{\theta}}{\widehat{SE}(\hat{\theta}^*)}.$$

Det praktiske:

- ▶ Simuler n_{boot} bootstrap værdier $T_1^*, \dots, T_{n_{boot}}^*$.
- ▶ Bootstrap p -værdi beregnes som i permutationstest,
 p -værdi = andel af bootstrap T^* som er mindst så ekstrem som t (obs. t indregnet),
e.g. p -værdi = $(\sum_{i=1}^{n_{boot}} \mathbf{1}(T_i^* \geq t) + 1) / (n_{boot} + 1)$, når $H_A : \theta > \theta_0$.

Bootstrap T tests anbefales

- ▶ frem for almindelig T -test, når stikprøvefordelingen af $\hat{\theta}$ er skæv.
- ▶ frem for permutationstests til sammenligning af middelværdier, når variansen er meget forskelligt. Når varianserne ikke er vildt forskelligt, foretrækkes permutationstests frem for bootstrap- t -test.
- ▶ stikprøven bør ikke være alt for lille ($n = 30$ er fint).

temmeligt

permutationstest
tests, som
fordelingen er
éns

Eksempel

Thursday, 12 March 2020 09.48

Eksempel 8.4: Arsenforurening af grundvand i Bangladesh

Situation: der anbefales en arsenindhold på maks $100 \mu\text{g/l}$ i vand til vanding i landbrug.

Det videnskabelige problem: Er grundvandet i Bangladesh OK?

Hypoteser: $H_0: \mu = 100$ versus $H_A: \mu > 100$.

 Ville en miljøaktivist vælge samme alternativ hypotese?

Eksempel 8.4: Arsenforurening af grundvand i Bangladesh

```
t.test(Bangladesh$Arsenic, mu = 100, alt = "greater")
t = 1.3988, df = 270, p-value = 0.08151
...
```

To obtain the P -value from the bootstrap t approach:

```
Arsenic <- Bangladesh$Arsenic
observedT <- t.test(Arsenic, mu = 100)$statistic
xbar <- mean(Arsenic)
n <- length(Arsenic)
Tstar <- numeric(N)
for (i in 1:N)
{
  bootx <- sample(Arsenic, n, replace = TRUE)
  Tstar[i] <- (mean(bootx) - xbar) / (sd(bootx) / sqrt(n))
}
hist(Tstar)
abline(v = observedT)

(sum(Tstar >= observedT) + 1) / (N + 1)
```

[notebook](#)

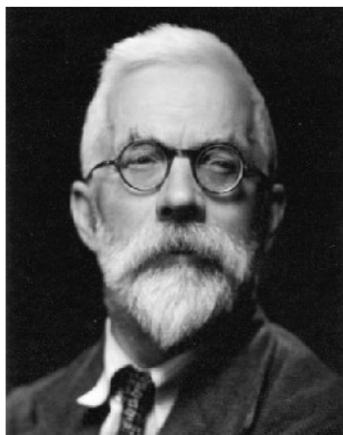
Hypotesetests: to forskellige tilgangsmåder

Tests skal hjælpe os at vurdere, om en observerede stikprøve kan forklares som udfald af en nulmodel, dvs, ved en nulhypotese.

P-værdier: Tilgang som blev gjort populær af Ronald Aylmer Fisher

Vurdering af hypoteser: R.A. Fisher vs. J. Neyman og E.S. Pearson

Sir R.A. Fishers's filosofi



Fisher (og mange andre):

Validere nulhypotesen ved hjælp af p-værdien.

p-værdien angiver sandsynligheden for, at se et eksperimentelt resultat som er mindst lige så ekstrem som det observerede. Hvis p-værdien er lille, burde vi undersøge sagen nærmere.

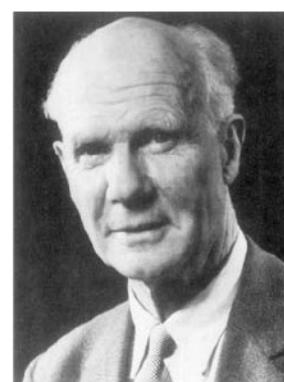
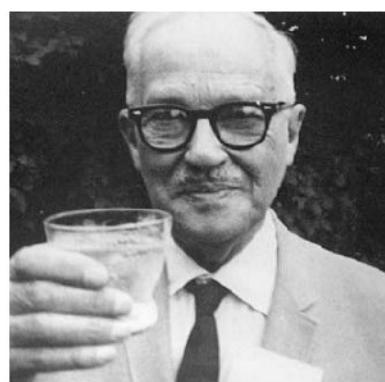
☞ H_A spiller ingen rolle i sig selv – vi bruger den kun for at fastlægge hvad "ekstrem" betyder.

$$\text{stikprøve } X \longrightarrow p\text{-værdi} \in [0, 1]$$

Jerzy Neyman og Egon Pearson prøvede at kaste det hele i en matematisk formalismus og endte med en ny tilgang.

Vurdering af hypoteser: R.A. Fisher vs. J. Neyman og E.S. Pearson

Neyman-Pearson hypotesetests



Jerzy Neyman(1894–1981), Egon Pearson (1895–1980)

Filosofi: Der antages, at enten H_0 eller H_A er sand.

Jerzy Neyman (1894–1981), Egon Pearson (1895–1980)

Filosofi: Der antages, at enten H_0 eller H_A er sand.

Valg mellem to hypoteser H_0 eller H_A skal afgøres vha. test.

Kontroller sandsynlighederne for fejlagtig beslutning.

kodering

Stikprøve $x \longrightarrow$ beslutning $\begin{cases} \text{forkast } H_0 & 0 \\ \text{Rj. forkastet } H_0 & 1 \end{cases}$

Type 1 og type 2 fejl

Hvilke situationer er muligt?

		Beslutning	
		forkaste ikke H_0	forkaste H_0
Sandheden	H_0 er sandt	✓ ☺	type 1 fejl
	H_A er sandt	type 2 fejl	✓

H_0 er sandt

Sandsynligheder vi ønsker at kontrollere:

$$P(\text{type 1 fejl}) = P(H_0 \text{ forkastes} \mid H_0 \text{ er sandt})$$

$$P(\text{type 2 fejl}) = P(H_0 \text{ forkastes ej} \mid H_A \text{ er sandt})$$

afhænger af den specielle værdi af H_A

Eksempel for beregning af type 1 fejl

Eksempel 8.10 og 8.12: Normalfordelingsmodel med kendt varians

Example 8.10 We return to math SAT scores for 2009 college-bound seniors (scores are distributed $N(515, 116^2)$). Suppose local educators in a certain city want to know how their students compare with the national average. The educators have also decided that if their students average much lower than the national average of 515 points, then they will request more money from the city council for new teaching reforms. The educators will obtain a random sample of scores and test $H_0: \mu = 515$ versus $H_A: \mu < 515$, where μ denotes the mean math SAT score in their city. If their sample size is 100 and they decide that a sample average of 505 or less is their criterion for making the funding request, what is the probability they make a type I error? Assume that the standard deviation of scores in the city is $\sigma = 116$.

Data: 100 SAT test resultater (Scholastic Aptitude Test), x_1, \dots, x_{100} .

Formål: Undersøg, om det gennemsnitlige resultat som førhen låg på 515 pts er blevet dårligere.

Model: $X_1, \dots, X_{100} \stackrel{\text{i.i.d.}}{\sim} N(\mu, 116^2)$.

Hypoteser: $H_0: \mu = 515$ vs. $H_A: \mu < 515$.

Test: vi beslutter os for H_0 hvis $\bar{x} > 505$ og for H_A hvis $\bar{x} \leq 505$.

Eksempel 8.10: Sandsynlighed for type 1 fejl

Test: vi beslutter os for H_0 hvis $\bar{x} > 505$ og forkaster H_0 hvis $\bar{x} \leq 505$.

$$\begin{aligned} P(\text{type 1 fejl}) &= P(H_0 \text{ forkastes} \mid H_0 \text{ er sand}) \\ &= P(\bar{X} \leq 505 \mid X_1, \dots \stackrel{\text{i.i.d.}}{\sim} N(515, 116^2)) \\ &= P(\bar{X} \leq 505 \mid \bar{X} \sim N(515, \frac{116^2}{100})) \\ &= P(Z \leq \underbrace{\frac{505 - 515}{116/\sqrt{100}}}_{=-0.8621} \mid Z \sim N(0, 1)) \quad Z = \frac{\bar{X} - 515}{116/\sqrt{100}} \\ &= \Phi(-0.8621) = 0.1943 \end{aligned}$$

Kontrol af type 1 fejl ssh vha kritisk område

Neyman-Pearson signikanstest

Mål: konstruer test således, at ssh for type 1 fejl kontrolleres.

Princippet af signikanstests iflg Neyman og Pearson:

Byg et test der forkaster H_0 , alt efter hvordan den observerede værdi af teststørrelse T ser ud.

Toleransgrænsne for type 1 fejl ssh α fastlægges i forvejen.

Definition 8.2:

Signifikansniveauet α er den største sandsyndighed for type 1 fejl som vi synes er acceptabel.

Definition 8.3:

Betrægt en test af H_0 mod H_A til signifikansniveau α , hvor der bruges en teststørrelse T .

Mængden af alle værdier af T som medfører at H_0 forkastes, betegnes som **kritisk område R** af T . Grænserne af R betegnes som **kritiske værdier**.

- Teststørrelse $T(x) \in R$ $T: X \rightarrow \mathbb{R}$
 - kritisk område R
 - beslutning : $T(x) \in R \Leftrightarrow H_0$ forkastes
 $T(x) \notin R \Leftrightarrow H_0$ forkastes ej
- ensidet test ↴ kritisk værdi
- $$R = (-\infty, C] \quad \text{hvis små værdie af } T$$
- henlyder, at H_0 må være sandt
- $$R = [C, \infty) \quad \text{hvis store værdie af } T \text{ ces hyppigt under } H_0$$
- to sidet test
- $$R = (-\infty, C_1] \cup [C_2, \infty)$$

Eksempel 8.10 og 8.12: Normalfordelingsmodel med kendt varians

Example 8.10 We return to math SAT scores for 2009 college-bound seniors (scores are distributed $N(515, 116^2)$). Suppose local educators in a certain city want to know how their students compare with the national average. The educators have also decided that if their students average much lower than the national average of 515 points, then they will request more money from the city council for new teaching reforms. The educators will obtain a random sample of scores and test $H_0: \mu = 515$ versus $H_A: \mu < 515$, where μ denotes the mean math SAT score in their city. If their sample size is 100 and they decide that a sample average of 505 or less is their criterion for making the funding request, what is the probability they make a type I error? Assume that the standard deviation of scores in the city is $\sigma = 116$.

Data: 100 SAT test resultater (Scholastic Aptitude Test), x_1, \dots, x_{100} . *Stikprøve*

Formål: Undersøg, om det gennemsnitlige resultat som førhen låg på 515 pts er blevet dårligere.

Model: $X_1, \dots, X_{100} \stackrel{\text{i.i.d.}}{\sim} N(\mu, 116^2)$. *kendt varians*

Hypoteser: $H_0: \mu = 515$ vs. $H_A: \mu < 515$.

Test: vi beslutter os for H_0 hvis $\bar{x} \geq 505$ og for H_A hvis $\bar{x} < 505$.

$$R = (-\infty, 505] \\ T(x) = \bar{x}$$

Eksempel 8.10: Sandsynlighed for type 1 fejl

Test: vi beslutter os for H_0 hvis $\bar{x} \geq 505$ og for H_A hvis $\bar{x} < 505$.

$$\begin{aligned} P(\text{type 1 fejl}) &= P(H_0 \text{ forkastes} \mid H_0 \text{ er sand}) \\ &= P(\bar{X} < 505 \mid X_1, \dots, X_{100} \stackrel{\text{i.i.d.}}{\sim} N(515, 116^2)) \\ &= P(\bar{X} < 505 \mid \bar{X} \sim N(515, \frac{116^2}{100})) \\ &= P(Z < \frac{505 - 515}{116/\sqrt{100}} \mid Z \sim N(0, 1)) \quad Z = \frac{\bar{X} - 515}{116/\sqrt{100}} \\ &= \Phi(-\frac{505 - 515}{116/\sqrt{100}}) \quad = -0.8621 \\ &= \Phi(-0.8621) = 0.1943 \quad ; R \\ &\quad pnorm(-0.8621) \end{aligned}$$

☞ Hvordan kan sandsynligheden for type 1 fejl kontrolleres, dvs. skulle grænsen (som var 505) vælges således at $P(\text{type 1 fejl}) = \alpha$?

signifikansniveau

Model: $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$.

Hypoteser: $H_0: \mu = \mu_0$ vs. $H_A: \mu < \mu_0$.

Test: Forkast H_0 , hvis $\bar{X} \leq C$.

Opgaven: Find grænse C således, at

$$P(\bar{X} \leq C \mid \bar{X} \sim N(\mu_0, \sigma^2/n)) \leq \alpha$$

Løsning:

$$C = \mu_0 + q \cdot \frac{\sigma}{\sqrt{n}}, \quad q = \Phi^{-1}(\alpha)$$

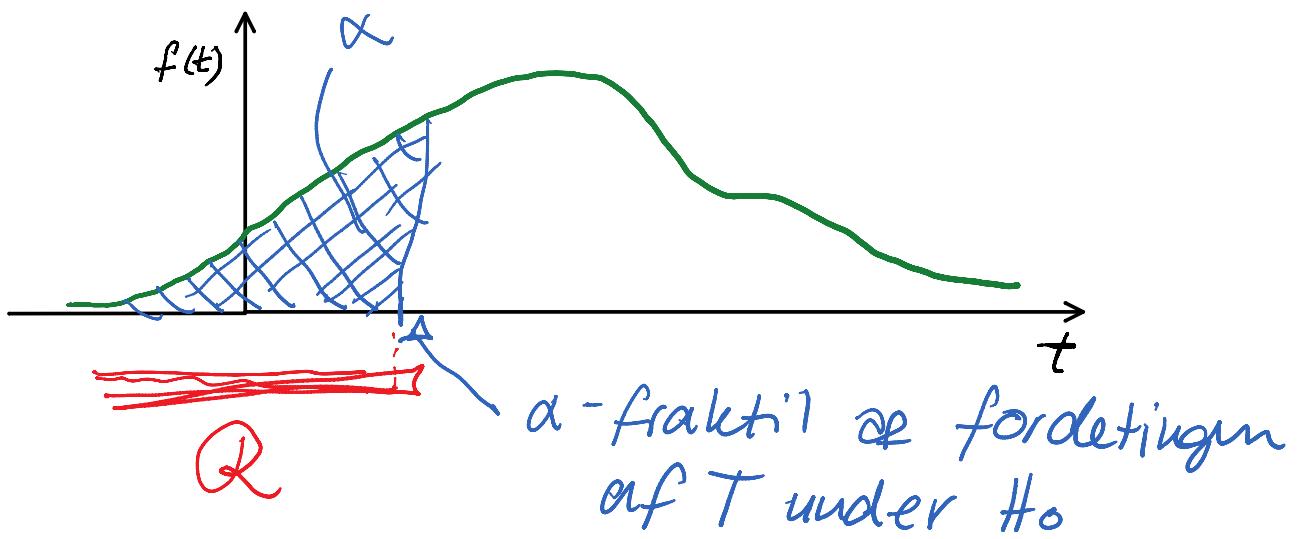
I eksemplet med SAT test (Example 8.10 og 8.12): der ønskes $\alpha = 0.1$. Kritisk værdi:

$$C = \mu_0 + \Phi^{-1}(\alpha) \cdot \frac{\sigma}{\sqrt{n}} = 515 + (-1.2816) \cdot \frac{116}{10} = 500.13.$$

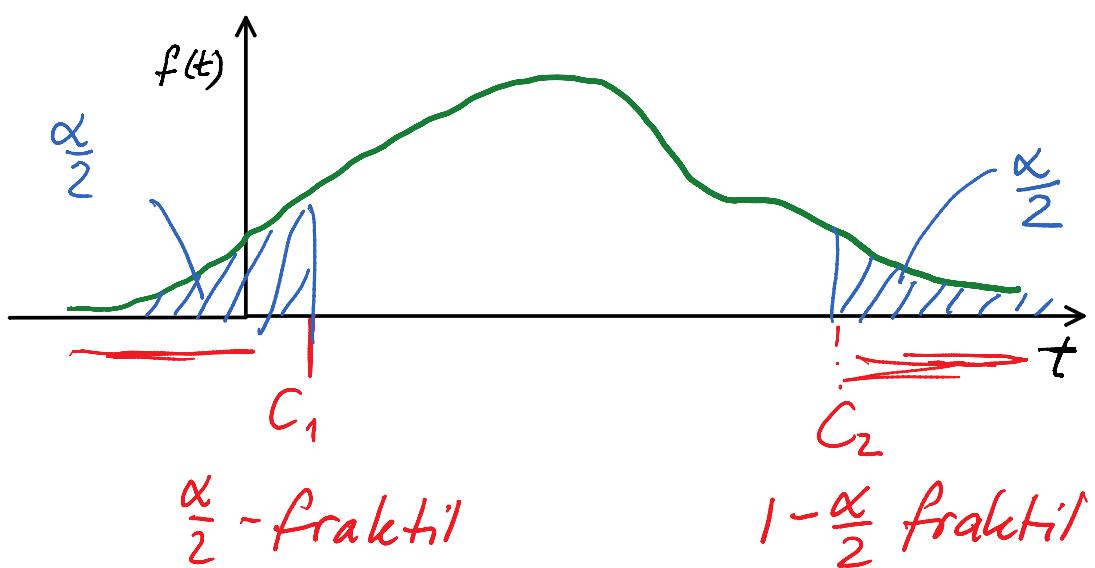
Beregning af kritiske værdier

Ingredienser:

- fordeling af teststørrelse T under H_0
- kriterier, hvornår T anses som ekstremer
 - små
 - store
 - både store og små
- signifikansniveau α



tosided test



- Type I fejl, signifikansniveau, kritiske værdier: eksempel med diskret fordeling

Eksempel 8.13:

En terning mistænkes ikke at være fair. Specielt antal af 

Eksperiment: 60 kast med terningenen, bestem antal X af 

Model: udgangene af de enkelte kast er uafhængige og identisk fordelte.

$$X \sim \text{Bin}(n=60, p)$$

Nulhypotese: $H_0: p = 1/6 \xrightarrow{\text{under } H_0} \mathbb{E} X = 10$

Alternativ $H_A: p \neq 1/6$

Tosided test: Forkast nulhypotesen, hvis den observerede X er enten meget lav eller meget høj.

$$\leq C_1 \quad X \geq C_2 \quad R = (-\infty, C_1] \cup [C_2, \infty)$$

Signifikansniveau: $\alpha = 0.05$

$$P(X \in R | H_0) \leq \alpha$$

$$L = P(X \leq C_1) + P(X \geq C_2) \leq \alpha$$

$$\begin{matrix} \leq \frac{\alpha}{2} & \leq \frac{\alpha}{2} \\ 0.025 & 0.025 \end{matrix}$$

$$P(X \leq C_1) : pbiniom(C_1, size=60, prob=1/6) \leq 0.025$$

$$P(X \geq C_2) = 1 - P(X < C_2) = 1 - P(X \leq (C_2-1)) \\ = 1 - pbiniom(C_2-1, 60, 1/6) \leq 0.025$$

Table 8.2 Cumulative probabilities for Binom(60, 1/6).

C_1	0	1	2	3	4	5
$P(X \leq C_1)$	1.77×10^{-5}	2.307×10^{-4}	0.0015	0.0063	<u>0.0202</u>	0.0512
C_2	165	176	187	19	20	210
$P(X \geq C_2)$	0.0648	0.0338	<u>0.0164</u>	0.0074	0.0031	0.0012

$$P(X \leq C_1) \leq 0.025 \Rightarrow C_1 \leq 4$$

$$P(X \leq c_1) \leq 0.025 \Rightarrow c_1 \leq 4$$

$$P(X \geq c_2) \leq 0.025 \Rightarrow c_2 \geq 17$$

$$\mathcal{R} = \{0, 1, 2, 3, 4, 17, 18, 19, \dots, 60\}$$

$$P(X \in \mathcal{R} | H_0) = 0.0202 + 0.0164 = 0.0366 \leq 0.05$$

Definition

et test til det nominelle signifikansniveau α
kaldes konservativ, når $P(\text{type I fejl}) < \alpha$
liberal $> \alpha$

Type II fejl og styrke af tests (8.4.2)

Definition 8.4 **Power** is the probability of correctly rejecting a false null hypothesis.

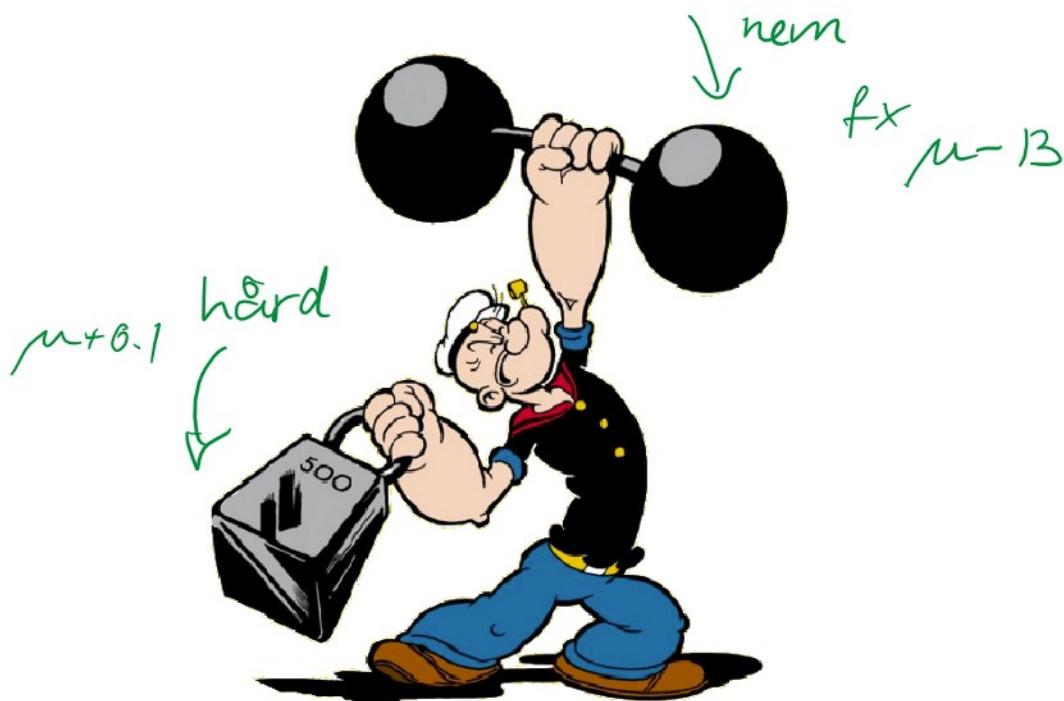
$$1 - \beta = P(\text{Reject } H_0 \mid H_A \text{ true}).$$

SSH for type 2 fejl
 $\beta = P(H_0 \text{ forkøres ej} \mid H_A \text{ er sand})$

Sammensæt hypotese: det alternative parameterværdi iadeholder mange elementer ...

$$\text{fx: } H_0: \mu = \mu_0 \quad H_A: \mu \neq \mu_0 \Rightarrow \text{fx } \mu = \mu_0 + 0.1 \\ \text{i modellen } N(\mu, \sigma^2) \quad \mu = \mu_0 - \beta$$

Styrke afhænger af den specielle H_A



Example 8.15 Suppose the heights of 2-year-old girls are normally distributed with a mean of 30 in. and a standard deviation of 6 in. Let μ denote the true mean heights of these girls. A researcher wishes to test

$$H_0: \mu = 30 \quad \text{versus} \quad H_A: \mu < 30.$$

She plans to obtain a random sample of 30 girls and measure their heights using $\alpha = 0.05$ for a significance level. What is the probability of correctly rejecting

$$H_0 : \mu = 30 \quad \text{versus} \quad H_A : \mu < 30$$

She plans to obtain a random sample of 30 girls and measure their heights using $\alpha = 0.05$ for a significance level. What is the probability of correctly rejecting the null hypothesis if the mean height of 2-year-old girls in this community is actually 27 in.?

$$X_1, \dots, X_{30} \sim N(\mu, \sigma^2 = 6^2)$$

$$H_0: \mu = 30 \quad \text{vs} \quad H_A: \mu < 30$$

$$\text{testes ved hjælp } \bar{X} = \frac{1}{30} \sum_{i=1}^{30} X_i, \quad \alpha = 0.05$$

? hvor stor er styrken når $\mu = 27$?

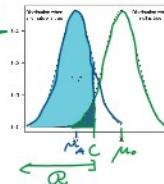
① find det kritiske område

$$Q = (-\infty, C], \text{ hvor}$$

$$C = \mu_0 + \frac{\sigma}{\sqrt{n}} \Phi^{-1}(\alpha)$$

$$= 30 + \frac{6}{\sqrt{30}} \cdot (-1.645)$$

$$= \underline{\underline{28.2}}$$



② beregn $1 - \beta$ = Styrken ved $\mu = 27$

$$P(H_0 \text{ forkastes} \mid \text{sandet } \mu = 27, \sigma = 6, X_i \sim N(27, 6^2))$$

$$= P(\bar{X} \leq 28.2 \mid \bar{X} \sim N(27, \frac{6^2}{30}))$$

$$= \underline{\underline{0.8632}}$$