

Matematisk Statistik

8. Forelæsning 25.02.2021

Klassisk statistik:

- ▶ Fordelingsfamilier
- ▶ Estimation i klassisk statistik
 - ▶ Momentmetoden
 - ▶ Maksimum likelihood metoden
- ▶ Estimatorernes egenskaber (det meste nok næste gang)

Hvad gør den “klassiske statistiker”, når den skal analysere data?

1. Bestemmer en **model**:


en **fordelingsfamilie** der generelt passer til problemet / data.

Modellen skal indeholde så mange parameter som nødvendigt, og så få som muligt.

2. **Fitter modellen**, dvs., fisker den passende fordeling i familien ved at **estimere** parameteren af modellen.

Teoretisk udgangspunkt:

- ▶ Observerede data $\mathbf{x} = (x_1, \dots, x_n)$ er en realisering af en vektor $\mathbf{X} = (X_1, \dots, X_n)$.
- ▶ X_1, \dots, X_n er uafhængige og identisk fordelt.
- ▶ Fordelingen af $X_i, i = 1, \dots, n$ er medlem i en **fordelingsfamilie**, i.e., en mængde af sandsynlighedsmål, givet ved en fordelingsfunktion.
- ▶ Fordelinger identificeres ved en parameter $\theta \in \Theta$, hvor Θ er **parameterrummet**.
- ▶ Klassisk inferens:
find den fordeling i familien, der synes mest passende som ophavsmand af de observerede data.
👉 bestem $\theta \in \Theta$.



$$\mathbb{H} = \left\{ \text{op}, \text{ryd}, \text{endelig}, \text{mål}, \text{måål} \right\}$$

$$\mathbf{X} = (b/a_1, b/a_2, b/a_3)$$

$$x_1 = ("op", "endelig", "ryd")$$

$$x_2 = ("mål", "mål", "måål")$$

Familier til kontinuerte data:

- ▶ Normalfordelinger $\{N(\mu, \sigma^2) : \underbrace{(\mu, \sigma)}_{\theta} \in \underbrace{\mathbb{R} \times \mathbb{R}^+}_{\Theta}\}$
Tæthedsfunktion $f(x; \mu, \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp(-\frac{(x-\mu)^2}{2\sigma^2}),$
udfaldsrum: $x \in \mathbb{R}.$
- ▶ Exponentialfordelinger $\{\text{Exp}(\lambda) : \lambda \in \mathbb{R}^+\}$
Tæthedsfunktion $f(x; \lambda) = \lambda \exp(-\lambda x),$
udfaldsrum: $x \in \mathbb{R}^+.$
- ▶ kender I flere?

Familier til diskrete data:

- ▶ Binomialfordelinger $\{\text{Binom}(n, p) : n \in \mathbb{N}, p \in [0, 1]\}$
sandsynlighedsfunktion: $f(x; n, p) = \binom{n}{x} p^x (1 - p)^{n-x}$,
udfaldsrum: $x \in \mathbb{N}_0$.

I de fleste anvendelser er antalsparameteren n kendt, så vi arbejder effektivt med familien $\{\text{Binom}(n, p) : p \in [0, 1]\}$, med kendt n .

- ▶ kender I flere?

Betragt en fordelingsfamilie $\{F(.; \theta), \theta \in \Theta\}$, og lad r være dimensionen af Θ .

Vi ønsker at fitte modellen til stikprøven (x_1, \dots, x_n) .

Momentestimatoren $\hat{\theta}(x_1, \dots, x_n) \in \Theta$ er den værdi, der opfylder, at, for $X \sim F(.; \theta)$,

$$E[X] = \frac{1}{n} \sum_{i=1}^n x_i, \quad E[X^2] = \frac{1}{n} \sum_{i=1}^n x_i^2, \quad \dots, \quad E[X^r] = \frac{1}{n} \sum_{i=1}^n x_i^r.$$

Husk, ved kontinuerte fordelinger på \mathbb{R}

$$E[X^k] = \int_{-\infty}^{\infty} x^k f(x; \theta) dx,$$

og ved diskrete fordelinger på \mathbb{Z}

$$E[X^k] = \sum_{x \in \mathbb{Z}} x^k f(x; \theta).$$

Eksempel 6.1:

Lad $x_1 = 3, x_2 = 4, x_3 = 3, x_4 = 7$ være udfald af uafhængige, identisk Poisson(λ) fordelte stokastiske variabler. Estimer λ fra stikprøven.

Eksempel 6.8:

$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}[0, \beta]$.

Estimer β , fra stikprøven: $x_1 = 4, x_2 = x_3 = 1, x_4 = 9$.

Eksempel 6.11:

X_1, X_2, \dots, X_n er uafhængige og identisk fordelt, med fordeling givet ved tæthedsfunktion

$$f(x) = \lambda e^{-\lambda(x-\delta)}, \text{ hvor } \lambda > 0 \text{ og } \delta > 0.$$

Estimer λ og δ , fra stikprøven: $x_1 = 3.5, x_2 = 3.9, x_3 = 4.0, x_4 = 4.7$.

Idé: fra hele fordelingsfamilien, valg den fordeling, hvor den observerede stikprøve x_1, \dots, x_n har den største "sandsynlighed".

Ingredienser / begreber:

- ▶ **Fordelingsfamilie** parametriseret med parameter θ ; tæthed eller sandsynlighed for $X = x$ er givet ved $f(x; \theta)$.
- ▶ **Likelihoodfunktion** (Definition 6.2 i MSRR)

$$L(\theta \mid x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

maksimeres af **maksimum likelihood estimatet** $\hat{\theta}_{\text{mle}}$ (tit skriver vi bare $\hat{\theta}$)

- ▶ **log likelihood**

$$\ln L(\theta \mid x_1, \dots, x_n) = \sum_{i=1}^n \ln f(x_i; \theta)$$

- ▶ **Score funktion**

$$u(\theta) = \frac{d \ln L}{d \theta}, \quad \text{ved flere dimensioner: } u(\theta_1, \dots, \theta_r) = \left(\frac{\partial \ln L}{\partial \theta_1}, \dots, \frac{\partial \ln L}{\partial \theta_r} \right)$$

Eksempel 6.1: Poissonfordelingen

Stikprøven $x_1 = 3, x_2 = 4, x_3 = 3, x_4 = 7$ antages at stamme fra en $\text{Poisson}(\lambda)$ -fordeling. Hvad er maksimum-likelihood estimatet?

Sandsynligheder for $\text{Poisson}(\lambda)$:

$$f(x; \lambda) = \frac{\lambda^x e^{-\lambda}}{x!}$$

Likelihoodfunktion:

$$\begin{aligned} L(\lambda \mid x_1 = 3, x_2 = 4, x_3 = 3, x_4 = 7) &= \frac{\lambda^3 e^{-\lambda}}{3!} \frac{\lambda^4 e^{-\lambda}}{4!} \frac{\lambda^3 e^{-\lambda}}{3!} \frac{\lambda^7 e^{-\lambda}}{7!} \\ &= \lambda^{17} e^{-4\lambda} / (3!4!3!7!) \end{aligned}$$

Find ekstrepunkter ved at sætte den første afledte lige 0:

$$\begin{aligned} \frac{dL(\lambda \mid \mathbf{x})}{d\lambda} &= \left(17\lambda^{16} e^{-4\lambda} + \lambda^{17} (-4e^{-4\lambda}) \right) / (3!4!3!7!) \\ &= (17 - 4\lambda) \lambda^{16} e^{-4\lambda} / (3!4!3!7!) \end{aligned}$$

$$\frac{dL(\lambda | \mathbf{x})}{d\lambda} = (17 - 4\lambda)\lambda^{16}e^{-4\lambda} / (3!4!3!7!)$$

altså

$$\left. \frac{dL(\lambda | \mathbf{x})}{d\lambda} \right|_{\lambda=\hat{\lambda}} = 0 \quad \Leftrightarrow \quad \hat{\lambda} = \frac{17}{4}.$$

Egentligt burde kontrolleres, om $\frac{d^2 L(\lambda | \mathbf{x})}{d\lambda^2} < 0$ for $\lambda = \hat{\lambda} \dots$

Idé: fra hele fordelingsfamilien, valg den fordeling, hvor den observerede stikprøve x_1, \dots, x_n har den største "sandsynlighed".

Ingredienser / begreber:

- ▶ **Fordelingsfamilie** parametriseret med parameter θ ; tæthed eller sandsynlighed for $X = x$ er givet ved $f(x; \theta)$.
- ▶ **Likelihoodfunktion** (Definition 6.2 i MSRR)

$$L(\theta \mid x_1, \dots, x_n) = \prod_{i=1}^n f(x_i; \theta)$$

maksimeres af **maksimum likelihood estimatet** $\hat{\theta}_{\text{mle}}$ (tit skriver vi bare $\hat{\theta}$)

- ▶ **log likelihood**

$$\ln L(\theta \mid x_1, \dots, x_n) = \sum_{i=1}^n \ln f(x_i; \theta)$$

- ▶ **Score funktion**

$$u(\theta) = \frac{d \ln L}{d \theta}, \quad \text{ved flere dimensioner:} \quad u(\theta_1, \dots, \theta_r) = \left(\frac{\partial \ln L}{\partial \theta_1}, \dots, \frac{\partial \ln L}{\partial \theta_r} \right)$$

Likelihood:

$$L(\lambda \mid \mathbf{x}) = \lambda^{17} e^{-4\lambda} / (3!4!3!7!),$$

log-Likelihood:

$$\ln L(\lambda \mid \mathbf{x}) = 17 \ln \lambda - 4\lambda - \ln(3!4!3!7!)$$

score funktion:

$$u(\lambda) = \frac{d \ln L(\lambda \mid \mathbf{x})}{d \lambda} = \frac{17}{\lambda} - 4,$$

score funktionens aflede:

$$u'(\lambda) = -\frac{17}{\lambda^2} < 0.$$

Eksempel 6.4: uniform fordeling

Betragt en stikprøve $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Unif}[0, \beta]$, med tæthed

$$f(x; \beta) = \begin{cases} 1/\beta, & 0 \leq x \leq \beta, \\ 0, & \text{ellers.} \end{cases}$$

Likelihoodfunktionen er

$$L(\beta) = \begin{cases} \frac{1}{\beta} \frac{1}{\beta} \dots \frac{1}{\beta}, & 0 \leq X_i \leq \beta \text{ for alle } X_i \text{ i stikprøven} \\ 0, & \text{hvis der findes en } i \text{ med } X_i < 0 \text{ eller } X_i > \beta \end{cases}$$

$L(\beta)$ bliver maksimalt, hvis β vælges så småt som muligt, således at ingen værdi X_i er større end β :

$$\hat{\beta}_{\text{mle}} = \max\{X_1, X_2, \dots, X_n\}.$$

☞ Det er et *globalt maksimum* af $L(\beta)$, derfor bruges her *ikke* score-funktionen.

Obs: hvis man definerer uniform fordelingen på en åben interval $(0, \beta)$, findes der ingen maksimum likelihood estimator, se eksempel 6.5.

Theorem 6.1.3 Let $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ be a random sample from a normal distribution with mean μ and standard deviation σ . The maximum likelihood estimates of μ and σ are

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \quad (6.3)$$

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}. \quad (6.4)$$

Bevis: Vi går direkte til log-likelihood, ved at bruge

$$\begin{aligned} f(x; \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \\ \Rightarrow \ln f(x; \mu, \sigma^2) &= -\frac{1}{2} \ln(2\pi) - \ln(\sigma) - \frac{1}{2\sigma^2} (x - \mu)^2 \end{aligned}$$

Med $\ln(L(\mu, \sigma^2)) = \sum_{i=1}^n \ln f(x; \mu, \sigma^2)$ fås

$$\ln(L(\mu, \sigma)) = -\frac{n}{2} \ln(2\pi) - n \ln(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2. \quad (6.5)$$

Theorem 6.1.3 Let $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ be a random sample from a normal distribution with mean μ and standard deviation σ . The maximum likelihood estimates of μ and σ are

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \quad (6.3)$$

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}. \quad (6.4)$$

Bevis: Vi går direkte til log-likelihood, ved at bruge

$$\begin{aligned} f(x; \mu, \sigma^2) &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \\ \Rightarrow \ln f(x; \mu, \sigma^2) &= -\frac{1}{2} \ln(2\pi) - \ln(\sigma) - \frac{1}{2\sigma^2} (x - \mu)^2 \end{aligned}$$

Med $\ln(L(\mu, \sigma^2)) = \sum_{i=1}^n \ln f(x; \mu, \sigma^2)$ fås

$$\ln(L(\mu, \sigma)) = -\frac{n}{2} \ln(2\pi) - n \ln(\sigma) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2. \quad (6.5)$$

Eksempel: ML estimation i normalfordelingen, fortsat

Setting the partial derivatives of the log-likelihood with respect to μ and σ equal to 0 gives a system of equations:

$$\frac{\partial(\ln(L(\mu, \sigma)))}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0, \quad (6.6)$$

$$\frac{\partial(\ln(L(\mu, \sigma)))}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (x_i - \mu)^2 = 0. \quad (6.7)$$

Fra (6.7) fås ML estimator

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

og, ved at indsætte dette i (6.8),

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

Vindhastigheden modelleres i litteraturen ved en **Weibull** fordeling:

$$f(x; k, \lambda) = \frac{kx^{k-1}}{\lambda^k} e^{-(x/\lambda)^k}, \quad x > 0.$$

En Weibull fordelte stokastisk variabel kan fås ved en transformation af $Z \sim \text{Exp}(1)$:

$$X = \frac{1}{\lambda} Z^{1/k}.$$

Med

$$\ln f(x; k, \lambda) = \ln k - k \ln \lambda + (k-1) \ln x - \left(\frac{x}{\lambda}\right)^k$$

er log-Likelihood:

$$\ln L(k, \lambda) = n \ln k - nk \ln \lambda + (k-1) \sum_{i=1}^n \ln x_i - \sum_{i=1}^n \left(\frac{x_i}{\lambda}\right)^k.$$

Thus, the log-likelihood is

$$\ln(L(k, \lambda)) = n \ln(k) - kn \ln(\lambda) + (k-1) \sum_{i=1}^n \ln(x_i) - \sum_{i=1}^n \left(\frac{x_i}{\lambda}\right)^k.$$

We next compute the partial derivatives of $\ln(L(k, \lambda))$ with respect to k and λ and set them equal to 0:

$$\frac{\partial(\ln(L(k, \lambda)))}{\partial k} = \frac{n}{k} - n \ln(\lambda) + \sum_{i=1}^n \ln(x_i) - \sum_{i=1}^n \left(\frac{x_i}{\lambda}\right)^k \ln\left(\frac{x_i}{\lambda}\right) = 0, \quad (6.9)$$

$$\frac{\partial(\ln(L(k, \lambda)))}{\partial \lambda} = \frac{-kn}{\lambda} + \frac{k}{\lambda^{k+1}} \sum_{i=1}^n x_i^k = 0. \quad (6.10)$$

From Equation (6.10), we find

$$\lambda^k = \frac{1}{n} \sum_{i=1}^n x_i^k, \quad (6.11)$$

and substituting this into Equation (6.9), we obtain

$$\frac{1}{k} + \frac{1}{n} \sum_{i=1}^n \ln(x_i) - \frac{1}{\alpha} \sum_{i=1}^n x_i^k \ln(x_i) = 0, \quad (6.12)$$

where $\alpha = \sum_{i=1}^n x_i^k$.


Ligningen løses numerisk.


Autorens (Chiharas) data (udsnit):

Table 6.1 Sample of wind speeds (m/s) from Carleton College turbine.


Feb 14	Feb 15	Feb 16	Feb 17	Feb 18	Feb 19
7.8	8.9	9.7	7.7	6.4	3.1

Fordelingsfunktion, fittet til data:







Low accuracy
Low precision



Low accuracy
High precision



High accuracy
Low precision



High accuracy
High precision

Definition

Bias af en estimator $\hat{\theta}$ til parameteren θ er givet ved

$$\text{Bias } \hat{\theta} = E \hat{\theta} - \theta.$$

Estimatoren $\hat{\theta}$ kaldes for **middelret** eller **central** (unbiased) hviss $E \hat{\theta} = \theta$, dvs, $\text{Bias } \hat{\theta} = 0$.

Betragt en Bernoulli eksperiment, bestående af n uafhængige stokastiske variable X_1, \dots, X_n , der antager værdien 1 med sandsynlighed p , og er lig 0 ellers.

Andelen \hat{p} af positive udfald i n uafhængige Bernoulli eksperimenter,

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$$

er en estimator til andelen p i populationen.

Proposition 6.3.1 If X_1, X_2, \dots, X_n are Bernoulli random variables with parameter p , then $E[\hat{p}] = p$.

Proof. Let $X = \sum_{i=1}^n X_i$. Then

$$E[\hat{p}] = E\left[\frac{X}{n}\right] = \frac{np}{n} = p.$$

□

Theorem 6.3.2 Let X_1, X_2, \dots, X_n be independent random variables from a distribution with unknown $\text{Var}[X_i] = \sigma^2 < \infty$. Then an unbiased estimator of σ^2 is $S^2 = (1/(n-1)) \sum_{i=1}^n (X_i - \bar{X})^2$.

Værktøj til beviset: (se side 164 MSRR)

- ▶ **Proposition A.2.1** $\text{Var}[X] = E[(X - \mu)^2] = E[X^2] - \mu^2$.
- ▶ **Theorem A.4.1** Let X_1, X_2, \dots, X_n be identically distributed random variables with mean μ and variance σ^2 .
Then $E[\bar{X}] = \mu$.
If, in addition, X_1, X_2, \dots, X_n are independent, then $\text{Var}[\bar{X}] = \sigma^2/n$.

- ▶ samt identiteten

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \left(\sum_{i=1}^n X_i^2 \right) - n\bar{X}^2. \quad (6.16)$$

(se også side 164 MSRR)

Definition

Lad X_1, X_2, \dots, X_n være uafhængige, identisk fordelte stokastiske variable fra en fordeling med varians $\sigma^2 < \infty$. Stikprøvefunktionen

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

kaldes **stikprøvevarians** (sample variance).

Stikprøvevariansen er en middelfret estimator af σ^2 .

Eksempel: den uniforme fordeling

Example 6.12 Let X_1, X_2, \dots, X_n be i.i.d. from $\text{Unif}[0, \beta]$. We have already seen that the MLE of β is $\hat{\beta}_{\text{mle}} = X_{\text{max}}$.

With $f_{\text{max}}(x) = (n/\beta^n)x^{n-1}$ (see Corollary 4.2.2), we have

$$\begin{aligned} E[X_{\text{max}}] &= \int_0^\beta x \frac{n}{\beta^n} x^{n-1} dx \\ &= \frac{n}{n+1} \beta, \end{aligned}$$

derfor er $\hat{\beta}_{\text{mle}} = X_{\text{max}}$ ikke middeleret, men

$$\hat{\beta} = \frac{n+1}{n} X_{\text{max}}$$

er middeleret.

En anden middeleret estimator er den fra moment metoden,


$$\hat{\beta}_{\text{mom}} = 2\bar{X}.$$

Betragt en fordelingsfamilie med parameter θ .

I nogle situationer udtrykkes samme familien vha en anden parameter $\rho = h(\theta)$, hvor h er en **bijektiv** funktion.

Eksempel (R):

`rgamma(n, shape, rate = 1, scale = 1/rate).`



$$\Theta = \{ \text{B}, \text{A}, \text{D}, \text{S}, \text{K} \}$$

$$h(\Theta) = \{23, 45, 33, 39, 36\}$$

$$\hat{\theta} \text{ er } \begin{cases} \text{ML-estimator} \\ \text{moment-estimator} \end{cases} \text{ af } \theta \implies \hat{\rho} = h(\hat{\theta}) \text{ er } \begin{cases} \text{ML-estimator} \\ \text{moment-estimator} \end{cases} \text{ af } \rho$$

Normalfordelingen kan parametriseres ved (μ, σ) frem for (μ, σ^2) — se den måde R gør det på, fx `rnorm(n, mean = μ , sd = σ)`.

ML estimatorer til σ^2 og σ er givet ved

$$\widehat{\sigma^2} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \implies \hat{\sigma} = \sqrt{\widehat{\sigma^2}} = \left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^{1/2}$$

Ekspontialfordelingen parametriseres nogle gange med skala $\beta = 1/\lambda$ frem for rate λ . Så skrives tætheden

$$f(x; \lambda) = \lambda e^{-\lambda x} \quad \text{som} \quad \tilde{f}(x; \beta) = \frac{1}{\beta} e^{-x/\beta}.$$

ML estimator til λ og $\beta = 1/\lambda$:

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i} \implies \hat{\beta} = \frac{1}{n} \sum_{i=1}^n x_i$$

Antag, at $\hat{\theta}$ er en god estimerer for θ . Vi vil dog gerne estimere $g(\theta)$ for en given funktion g . Er $g(\hat{\theta})$ også en god estimerer?

Svar:

- ▶ Hvis $\hat{\theta}$ er **ML**-estimator for θ , så er $g(\hat{\theta})$ også ML estimerer for $g(\theta)$.
- ▶ Hvis $\hat{\theta}$ er en **middelvej** estimerer for θ , så er $g(\hat{\theta})$ generelt set **ikke** middelvej for $g(\theta)$.



Jensens ulighed^a

Lad g være en streng konveks funktion og X en ikke degenereret stokastisk variabel^b. Så er

$$g(E X) < E g(X).$$

^aJohan Jensen, 1908

^ben stok. variabel kaldes degenereret, hvis den kun antager 1 værdi

Jensens ulighed betyder for en unbiased estimator $\hat{\theta}$, hvis g er streng konveks:

$$E g(\hat{\theta}) > g(\theta).$$

Eksempel (MSRR, side 166): For $\text{Unif}[0, \beta]$ fordelingen er $\hat{\beta} = 2\bar{X}$ middelret. Men $(\hat{\beta})^2 = 4\bar{X}^2$ er ikke middelret for β^2 :

$$\begin{aligned} E[4\bar{X}^2] &= 4 E[\bar{X}^2] = 4(\text{Var}[\bar{X}] + E[\bar{X}]^2) \\ &= 4 \left(\frac{\beta^2}{12n} + \left(\frac{\beta}{2} \right)^2 \right) = \beta^2 + \frac{\beta^2}{3n} \end{aligned}$$

Altså $E[\hat{\beta}^2] > \beta^2$.

Definition

En estimator $\hat{\theta}$ kaldes **asymptotisk middeltret**, hvis

$$\lim_{n \rightarrow \infty} E \hat{\theta}(X_1, \dots, X_n) = \theta,$$

for uafhængige $X_1, X_2, \dots \sim F(., \theta)$.

Eksempler

- ▶ ML estimatoren til $N(\mu, \sigma^2)$ normalfordelingens varians er asymptotisk middeltret:

$$E \hat{\sigma}^2 = \frac{n-1}{n} \sigma^2 \xrightarrow{n \rightarrow \infty} \sigma^2.$$

- ▶ ML estimator for parameter β i $\text{Unif}[0, \beta]$ -fordelingen er X_{\max} . Den er asymptotisk middeltret:

$$\lim_{n \rightarrow \infty} E[X_{\max}] = \lim_{n \rightarrow \infty} \frac{n}{n+1} \beta = \beta$$