


# Matematisk Statistik

## 9. Forelæsning 02.03.2021

Estimation i klassisk statistik: punktestimatorernes egenskaber

- ▶ bias / centralitet,
- ▶ efficiens,
- ▶ MSE (mean square error),
- ▶ konsistens,
- ▶ omparametrisering, Jensens ulighed .



### Definition

**Bias** af en estimator  $\hat{\theta}$  til parameteren  $\theta$  er givet ved

$$\text{Bias } \hat{\theta} = E \hat{\theta} - \theta.$$

Estimatoren  $\hat{\theta}$  kaldes for **middelret** eller **central** (unbiased) hviss  $E \hat{\theta} = \theta$ , dvs,  $\text{Bias } \hat{\theta} = 0$ .

Betragt en Bernoulli eksperiment, bestående af  $n$  uafhængige stokastiske variable  $X_1, \dots, X_n$ , der antager værdien 1 med sandsynlighed  $p$ , og er lig 0 ellers.

Andelen  $\hat{p}$  af positive udfald i  $n$  uafhængige Bernoulli eksperimenter,

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$$

er en estimator til andelen  $p$  i populationen.

**Proposition 6.3.1** If  $X_1, X_2, \dots, X_n$  are Bernoulli random variables with parameter  $p$ , then  $E[\hat{p}] = p$ .

*Proof.* Let  $X = \sum_{i=1}^n X_i$ . Then

$$E[\hat{p}] = E\left[\frac{X}{n}\right] = \frac{np}{n} = p.$$

□

**Theorem 6.3.2** Let  $X_1, X_2, \dots, X_n$  be independent random variables from a distribution with unknown  $\text{Var}[X_i] = \sigma^2 < \infty$ . Then an unbiased estimator of  $\sigma^2$  is  $S^2 = (1/(n-1)) \sum_{i=1}^n (X_i - \bar{X})^2$ .

Værktøj til beviset: (se side 164 MSRR)

- ▶ **Proposition A.2.1**  $\text{Var}[X] = E[(X - \mu)^2] = E[X^2] - \mu^2$ .
- ▶ **Theorem A.4.1** Let  $X_1, X_2, \dots, X_n$  be identically distributed random variables with mean  $\mu$  and variance  $\sigma^2$ .  
Then  $E[\bar{X}] = \mu$ .  
If, in addition,  $X_1, X_2, \dots, X_n$  are independent, then  $\text{Var}[\bar{X}] = \sigma^2/n$ .

- ▶ samt identiteten

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \left( \sum_{i=1}^n X_i^2 \right) - n\bar{X}^2. \quad (6.16)$$

(se også side 164 MSRR)

### Definition

Lad  $X_1, X_2, \dots, X_n$  være uafhængige, identisk fordelte stokastiske variable fra en fordeling med varians  $\sigma^2 < \infty$ . Stikprøvefunktionen

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

kaldes **stikprøvevarians** (sample variance).

Stikprøvevariansen er en middelfret estimator af  $\sigma^2$ .

## Eksempel: den uniforme fordeling

---

**Example 6.12** Let  $X_1, X_2, \dots, X_n$  be i.i.d. from  $\text{Unif}[0, \beta]$ . We have already seen that the MLE of  $\beta$  is  $\hat{\beta}_{\text{mle}} = X_{\text{max}}$ .

With  $f_{\text{max}}(x) = (n/\beta^n)x^{n-1}$  (see Corollary 4.2.2), we have

$$\begin{aligned} E[X_{\text{max}}] &= \int_0^\beta x \frac{n}{\beta^n} x^{n-1} dx \\ &= \frac{n}{n+1} \beta, \end{aligned}$$

derfor er  $\hat{\beta}_{\text{mle}} = X_{\text{max}}$  ikke middelfret, men

$$\hat{\beta} = \frac{n+1}{n} X_{\text{max}}$$

er middelfret.

En anden middelfret estimator er den fra moment metoden,

$$\hat{\beta}_{\text{mom}} = 2\bar{X}.$$

## Definition

En estimator  $\hat{\theta}$  kaldes **asymptotisk middeltret**, hvis

$$\lim_{n \rightarrow \infty} E \hat{\theta}(X_1, \dots, X_n) = \theta,$$

for uafhængige  $X_1, X_2, \dots \sim F(., \theta)$ .

## Eksempler

- ▶ ML estimatoren til  $N(\mu, \sigma^2)$  normalfordelingens varians er asymptotisk middeltret:

$$E \hat{\sigma}^2 = \frac{n-1}{n} \sigma^2 \xrightarrow{n \rightarrow \infty} \sigma^2.$$

- ▶ ML estimator for parameter  $\beta$  i  $\text{Unif}[0, \beta]$ -fordelingen er  $X_{\max}$ . Den er asymptotisk middeltret:

$$\lim_{n \rightarrow \infty} E[X_{\max}] = \lim_{n \rightarrow \infty} \frac{n}{n+1} \beta = \beta$$

## Motivation

Tit findes mange middelrette estimatorer for den samme parameter  
— hvilken skal så foretrækkes?

### Eksempel:

$\mathbf{X} = (X_1, X_2, X_3)$ , uafhængige og identisk fordelte variabler med middelværdi  $\mu$  og varians  $\sigma^2$ .

Både

$$\bar{X} = \frac{1}{3}(X_1 + X_2 + X_3)$$

og

$$Y = \frac{1}{6}X_1 + \frac{1}{3}X_2 + \frac{1}{2}X_3$$

er middelrette estimatorer for  $\mu$ .

Men

$$\text{Var } \bar{X} = \frac{1}{3}\sigma^2 \quad \text{mens} \quad \text{Var } Y = \frac{7}{18}\sigma^2.$$



### Definition

Hvis  $\hat{\theta}_1$  og  $\hat{\theta}_2$  både er **middelrette** estimatorer til samme parameter  $\theta$ , men  $\text{Var} \hat{\theta}_1 < \text{Var} \hat{\theta}_2$ , så kaldes  $\hat{\theta}_1$  for **mere efficient** end  $\hat{\theta}_2$ .

Den **relative efficiens** af middelterte estimatorer  $\hat{\theta}_1$  og  $\hat{\theta}_2$  defineres som


$$e(\hat{\theta}_1, \hat{\theta}_2) = \frac{\text{Var} \hat{\theta}_2}{\text{Var} \hat{\theta}_1}$$

## Eksempel 6.13: Uniform fordeling

To middelterte estimatorer til parameteren af en  $\text{Unif}[0, \beta]$ -fordeling:

$$\hat{\beta}_{\text{mom}}(X_1, \dots, X_n) = 2\bar{X}, \quad \hat{\beta}_{\text{mle}}(X_1, \dots, X_n) = \frac{n+1}{n} X_{\text{max}}$$

Experiment med R: til  $n = 25$ , stikprøvefordelingen



👉 ? hvilket histogram stammer fra  $\hat{\beta}_{\text{mom}}$ , hvilket fra  $\hat{\beta}_{\text{mle}}$ ?

? hvilken af de to estimatorer er mere efficient?

Flere teoretiske statistikere udledte i 1940'erne en **nedre grænse for variansen** af unbiased estimators. Denne grænse afhænger af fordelingen af de  $X_i$ .

If  $X_1, X_2, \dots, X_n$  are a random sample from a distribution with continuous pdf  $f(x; \theta)$  and  $f$  satisfies certain smoothness criteria, then any unbiased estimator  $\hat{\theta}$  of  $\theta$  satisfies

$$\text{Var}[\hat{\theta}] \geq \frac{1}{n E[(\partial/\partial\theta(\ln(f(X; \theta))))^2]}.$$

Udtrykket i nævneren kaldes for **Fisher information**,

$$\mathcal{J}(\theta) = E \left[ \left( \frac{\partial}{\partial\theta} \log f(X; \theta) \right)^2 \right] \quad (\text{MSRR: 6.17})$$

Det er variansen af score funktionen (fra ML estimationen).

Mere om Cramér-Rao uligheden: kandidatkurset "statistisk inferens".

Mean squared error kombinerer præcision og nøjagtighed i ét mål:

Definition (6.5)

**Mean squared error** af en estimator  $\hat{\theta}$  er defineret som

$$\text{MSE } \hat{\theta} = E[(\hat{\theta} - \theta)^2].$$

Proposition 6.3.3:

$$\text{MSE } \hat{\theta} = \text{Var } \hat{\theta} + (\text{Bias } \hat{\theta})^2.$$

👉 Når man sammenligner "gode" estimatorer for samme parameter, ser man tit at enten varians eller bias er lille.

## Eksempel 6.15: Estimatorer til $p$ i binomialfordelingen

---

Der betragtes antal af success i  $n$  uafhængige Bernoulli eksperimenter, altså en stokastisk variabel  $X \sim \text{Binom}(n, p)$ , med  $n$  kendt og  $p$  ukendt.

ML estimator til successraten:

$$\hat{p}_1 = \frac{X}{n},$$

$$E \hat{p}_1 = p, \quad \text{Var } \hat{p}_1 = p(1-p)/n \implies \text{MSE } \hat{p}_1 = \frac{p(1-p)}{n}.$$


har stor MSE når  $p$  ligger i nærheden af 0.5.

Alternativ estimator: tilføj en succes og en flop til data

$$\hat{p}_2 = \frac{X+1}{n+2}.$$

$$E \hat{p}_2 = \frac{np+1}{n+2}, \quad \text{Var } \hat{p}_2 = \frac{np(1-p)}{(n+2)^2} \implies \text{MSE } \hat{p}_2 = \frac{np(1-p) + (1-2p)^2}{(n+2)^2}.$$

Den nye estimator er biased, men har mindre MSE for mellemstore værdier af  $p$ , som ikke ligger tæt ved 0 eller 1.



**Figure 6.6** Mean square error against  $p$ ,  $n = 16$ .

Vi betragter den samme estimator  $\hat{\theta}$  anvendt på stikprøver med forskellige stikprøvestørrelser  $n$ :

Lad  $X_1, X_2, \dots$  være i.i.d. fra en fordeling med ukendt parameter  $\theta$ . Vi skriver:

$$\hat{\theta}_n := \hat{\theta}(X_1, \dots, X_n).$$

Hvad sker med voksende stikprøvestørrelse?

**Definition 6.6** For a random sample of size  $n$ , let  $\hat{\theta}_n$  denote an estimator of  $\theta$  and let  $\{\hat{\theta}_n\}_{n=0}^{\infty}$  be a sequence of estimators. The estimators are *consistent* for  $\theta$  if and only if

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| < \varepsilon) = 1 \quad (6.18)$$

for every  $\varepsilon > 0$ .

||

Denne type konvergens betegnes som **konvergens i sandsynlighed**.



Betragt  $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, 1)$ , og  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ .

Så er  $\bar{X}_n \sim N(\mu; \frac{1}{n})$ .

Beregn

$$\begin{aligned}\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \epsilon) &= \lim_{n \rightarrow \infty} P(\mu - \epsilon < \bar{X}_n < \mu + \epsilon) \\&= \lim_{n \rightarrow \infty} P\left(\frac{\mu - \epsilon - \mu}{\sqrt{1/n}} < \frac{\bar{X}_n - \mu}{\sqrt{1/n}} < \frac{\mu + \epsilon - \mu}{\sqrt{1/n}}\right) \\&= \lim_{n \rightarrow \infty} P\left(-\epsilon\sqrt{n} < Z < \epsilon\sqrt{n}\right), \quad Z \sim N(0, 1) \\&= \lim_{n \rightarrow \infty} (\Phi(\epsilon\sqrt{n}) - \Phi(-\epsilon\sqrt{n})) \\&= 1 - 0.\end{aligned}$$

Lad  $X$  være en stokastisk variabel,  $X \geq 0$ , og lad  $c > 0$ . Så gælder

$$P(X \geq c) \leq \frac{EX}{c}.$$

Bevis: på tavlen.

Lad  $X$  være en stokastisk variabel med endelig middelværdi  $\mu$  og endelig varians  $\sigma^2$ . Så gælder for alle  $k > 0$ :

$$P(|X - \mu| \geq k) \leq \frac{\sigma^2}{k^2}.$$

Bevis: på tavlen.

Korollar (Ex. 6.17):

$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$  er en konsistent estimator for  $E X = \mu$ , hvis både  $\mu$  og  $\text{Var } X$  er endelige.

Lad  $\hat{\theta}_n$  være en følge af estimatorer for  $\theta$ , som opfylder

$$\lim_{n \rightarrow \infty} E\hat{\theta}_n = \theta \quad \text{og} \quad \lim_{n \rightarrow \infty} \text{Var}\hat{\theta}_n = 0.$$

Så er  $\hat{\theta}_n$  en konsistent følge af estimatorer for  $\theta$ .

### Eksempel 6.17: Eks 6.16 igen

Betragt  $X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, 1)$ , og  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ .

Så er  $\bar{X}_n \sim N(\mu; \frac{1}{n})$ .

Så gælder  $\lim_{n \rightarrow \infty} E[\bar{X}_n] = \mu$  og  $\lim_{n \rightarrow \infty} \text{Var}[\bar{X}_n] = \lim_{n \rightarrow \infty} \sigma^2/n = 0$ .

Derved danner  $\bar{X}_1, \bar{X}_2, \dots$  en konsistent følge af estimatorer for  $\mu$ .

Standard Cauchy fordeling: lad  $Y_1, Y_2 \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$ . Så er  $X = Y_1 / Y_2 \sim \text{Cauchy}(0, 1)$ .

Tæthed af Cauchy( $\theta, \lambda$ )-fordelingen:

$$f(x; \theta, \lambda) = \frac{1}{\pi} \frac{\lambda}{\lambda^2 + (x - \theta)^2}.$$

Fordelingsfunktion:

$$F(x) = \int_{-\infty}^x f(u) du = \frac{1}{\pi} \arctan\left(\frac{x - \theta}{\lambda}\right) + \frac{1}{2}.$$

- ▶ Middelværdi og varians eksisterer ikke!  
(se opgave MSRR 2.11)
- ▶ Stikprøvegennemsnit  $\bar{X}_n$  har samme fordeling som  $X_1$   
 $\implies \bar{X}_n$  er ikke en konsistent estimator for  $\theta$ .

- ▶ Heldigvis er fordelingen symmetrisk om  $\theta$ . Altså er medianen egnet som estimator for  $\theta$ :

$$\hat{\theta}_n = \text{med}(X_1, \dots, X_n).$$

- ▶ Kvartiler:

$$F(x) = \frac{1}{4} \implies \arctan\left(\frac{x-\theta}{\lambda}\right) = \frac{\pi}{4} \implies x = \theta - \lambda \quad F(x) = \frac{3}{4} \implies x = \theta + \lambda$$

☞ Estimator for  $\lambda$ : half the interquartile range,

$$\hat{\lambda} = \text{IQR}(X_1, \dots, X_n)/2.$$



Vi undersøger lige, hvordan fordelingen af  $\hat{\theta}_n$  afhænger af  $n$ .


Betragt en fordelingsfamilie med parameter  $\theta$ .

I nogle situationer udtrykkes samme familien  
vha en anden parameter  $\rho = h(\theta)$ , hvor  $h$  er en  
**bijektiv** funktion.

Eksempel (R):

`rgamma(n, shape, rate = 1, scale = 1/rate).`

Parameteren “scale” kan bruges alternativt for  
“rate”.



$$\Theta = \{ \text{B}, \text{L}, \text{D}, \text{R}, \text{S} \}$$

$$h(\Theta) = \{23, 45, 33, 39, 36\}$$

**Proposition 6.3.5:** Estimatorer kan genbruges i omparametriserede modeller.

$$\hat{\theta} \text{ er } \begin{cases} \text{ML-estimator} \\ \text{moment-estimator} \end{cases} \text{ af } \theta \implies \hat{\rho} = h(\hat{\theta}) \text{ er } \begin{cases} \text{ML-estimator} \\ \text{moment-estimator} \end{cases} \text{ af } \rho$$

**Normalfordelingen** kan parametriseres ved  $(\mu, \sigma)$  frem for  $(\mu, \sigma^2)$  — se den måde R gør det på, fx `rnorm(n, mean =  $\mu$ , sd =  $\sigma$ )`.

ML estimatorer til  $\sigma^2$  og  $\sigma$  er givet ved

$$\widehat{\sigma^2} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \implies \hat{\sigma} = \sqrt{\widehat{\sigma^2}} = \left( \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^{1/2}$$

**Ekspontialfordelingen** parametriseres nogle gange med skala  $\beta = 1/\lambda$  frem for rate  $\lambda$ . Så skrives tætheden

$$f(x; \lambda) = \lambda e^{-\lambda x} \quad \text{som} \quad \tilde{f}(x; \beta) = \frac{1}{\beta} e^{-x/\beta}.$$

ML estimator til  $\lambda$  og  $\beta = 1/\lambda$ :

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i} \implies \hat{\beta} = \frac{1}{n} \sum_{i=1}^n x_i$$



Hvis  $\hat{\theta}$  er ML-estimator for  $\theta$ , så er  $g(\hat{\theta})$  også ML estimator for  $g(\theta)$ .

Hvis  $\hat{\theta}$  er moment-estimator for  $\theta$ , så er  $g(\hat{\theta})$  også moment estimator for  $g(\theta)$ .

### MEN..

Hvis  $\hat{\theta}$  er en middelret estimator for  $\theta$ , så er  $g(\hat{\theta})$  generelt set *ikke* middelret for  $g(\theta)$ .



### Jensens ulighed<sup>a</sup>

Lad  $g$  være en streng konveks funktion og  $X$  en ikke degenereret stokastisk variabel<sup>b</sup>. Så er

$$g(E X) < E g(X).$$

---

<sup>a</sup>Johan Jensen, 1908

<sup>b</sup>en stok. variabel kaldes degenereret, hvis den kun antager 1 værdi

Jensens ulighed betyder for en unbiased estimator  $\hat{\theta}$ , hvis  $g$  er streng konveks:

$$E g(\hat{\theta}) > g(\theta).$$

Eksempel (MSRR, side 166): For  $\text{Unif}[0, \beta]$  fordelingen er  $\hat{\beta} = 2\bar{X}$  middelret. Men  $(\hat{\beta})^2 = 4\bar{X}^2$  er ikke middelret for  $\beta^2$ :

$$\begin{aligned} E[4\bar{X}^2] &= 4 E[\bar{X}^2] = 4(\text{Var}[\bar{X}] + E[\bar{X}]^2) \\ &= 4 \left( \frac{\beta^2}{12n} + \left( \frac{\beta}{2} \right)^2 \right) = \beta^2 + \frac{\beta^2}{3n} \end{aligned}$$

Altså  $E[\hat{\beta}^2] > \beta^2$ .

## Theorem 6.3.6:

**maksimum likelihood estimatorer ofte er de bedste** blandt alle centrale (= middelfrette) estimatorer, i det de antager den minimale varians givet ved Cramér-Rao ulighed,

$$\text{Var}(\hat{\theta}_n) \geq \frac{1}{n \mathcal{I}(\theta)}, \quad \mathcal{I}(\theta) = \mathbb{E} \frac{\partial(\ln(f(X;\theta)))}{\partial \theta}.$$

For store  $n$  må man desuden antage, at  $\hat{\theta}_n$  er **approksimativt normalfordelt**.

## Eksempel 6.19

Lad  $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f$  med  $f(x; \theta) = \theta x^{\theta-1}$ , hvor  $\theta > 0$ ,  $0 < x < 1$ .

$$\log f(x; \theta) = \log \theta + (\theta - 1) \log x$$

MLE estimator er  $\hat{\theta}_n = -\frac{n}{\sum_{i=1}^n \ln(x_i)}$ .

For store  $n$  er  $\hat{\theta}_n \sim N(\theta, \theta^2/n)$ .