


Matematisk Statistik

10. Forelæsning 04.03.2021

- ▶ Punktestimatorer fortsætter:
 - ▶ omparametrisering, Jensens ulighed
 - ▶ asymptotik.
- ▶ Områdeestimatorer




Betragt en fordelingsfamilie med parameter θ .

I nogle situationer udtrykkes samme familien
vha en anden parameter $\rho = h(\theta)$, hvor h er en
bijektiv funktion.

Eksempel (R):

`rgamma(n, shape, rate = 1, scale = 1/rate).`

Parameteren “scale” kan bruges alternativt for
“rate”.



$$\Theta = \{ \text{B}, \text{L}, \text{D}, \text{R}, \text{S} \}$$

$$h(\Theta) = \{23, 45, 33, 39, 36\}$$

Proposition 6.3.5: Estimatorer kan genbruges i omparametriserede modeller.

$$\hat{\theta} \text{ er } \begin{cases} \text{ML-estimator} \\ \text{moment-estimator} \end{cases} \text{ af } \theta \implies \hat{\rho} = h(\hat{\theta}) \text{ er } \begin{cases} \text{ML-estimator} \\ \text{moment-estimator} \end{cases} \text{ af } \rho$$

Normalfordelingen kan parametriseres ved (μ, σ) frem for (μ, σ^2) — se den måde R gør det på, fx `rnorm(n, mean = μ , sd = σ)`.

ML estimatorer til σ^2 og σ er givet ved

$$\widehat{\sigma^2} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \implies \hat{\sigma} = \sqrt{\widehat{\sigma^2}} = \left(\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right)^{1/2}$$

Ekspontialfordelingen parametriseres nogle gange med skala $\beta = 1/\lambda$ frem for rate λ . Så skrives tætheden

$$f(x; \lambda) = \lambda e^{-\lambda x} \quad \text{som} \quad \tilde{f}(x; \beta) = \frac{1}{\beta} e^{-x/\beta}.$$

ML estimator til λ og $\beta = 1/\lambda$:

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i} \implies \hat{\beta} = \frac{1}{n} \sum_{i=1}^n x_i$$

Hvis $\hat{\theta}$ er ML-estimator for θ , så er $g(\hat{\theta})$ også ML estimator for $g(\theta)$.

Hvis $\hat{\theta}$ er moment-estimator for θ , så er $g(\hat{\theta})$ også moment estimator for $g(\theta)$.

MEN..

Hvis $\hat{\theta}$ er en middelret estimator for θ , så er $g(\hat{\theta})$ generelt set *ikke* middelret for $g(\theta)$.



Jensens ulighed^a

Lad g være en streng konveks funktion og X en ikke degenereret stokastisk variabel^b. Så er

$$g(E X) < E g(X).$$

^aJohan Jensen, 1908

^ben stok. variabel kaldes degenereret, hvis den kun antager 1 værdi

Jensens ulighed betyder for en unbiased estimator $\hat{\theta}$, hvis g er streng konveks:

$$E g(\hat{\theta}) > g(\theta).$$

Eksempel (MSRR, side 166): For $\text{Unif}[0, \beta]$ fordelingen er $\hat{\beta} = 2\bar{X}$ middeleret. Men $(\hat{\beta})^2 = 4\bar{X}^2$ er ikke middeleret for β^2 :

$$\begin{aligned} E[4\bar{X}^2] &= 4 E[\bar{X}^2] = 4(\text{Var}[\bar{X}] + E[\bar{X}]^2) \\ &= 4\left(\frac{\beta^2}{12n} + \left(\frac{\beta}{2}\right)^2\right) = \beta^2 + \frac{\beta^2}{3n} \end{aligned}$$

Altså $E[\hat{\beta}^2] > \beta^2$.

Theorem 6.3.6:

maksimum likelihood estimatorer ofte er de bedste blandt alle centrale (= middelfrette) estimatorer, i det de antager den minimale varians givet ved Cramér-Rao ulighed,

$$\text{Var}(\hat{\theta}_n) \geq \frac{1}{n\mathcal{I}(\theta)}, \quad \mathcal{I}(\theta) = \text{E} \left[\left(\frac{\partial(\ln(f(X;\theta)))}{\partial\theta} \right)^2 \right].$$

For store n må man desuden antage, at $\hat{\theta}_n$ er **approksimativt normalfordelt**.

Eksempel 6.19

Lad $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} f$ med $f(x;\theta) = \theta x^{\theta-1}$, hvor $\theta > 0$, $0 < x < 1$.

$$\log f(x;\theta) = \log\theta + (\theta - 1)\log x$$

MLE estimator er $\hat{\theta}_n = -\frac{n}{\sum_{i=1}^n \ln(x_i)}$.

For store n er $\hat{\theta}_n \sim N(\theta, \theta^2/n)$.